Detecção de Fraudes no Tráfego de Cliques em Propagandas de Aplicações Mobile

Gilson Santana - gcardososantana@gmail.com

02/11/2020

Informações gerais

Projeto da DSA como parte do treiamento Big Data Analytics com R e Microsoft Azure Machine Learning.

O projeto consiste na criação de modelo de Machine Learning que possa prever se um click para download de aplicativo é ou não fraudulento. Para esse trabalho foi utilizado a base de dados train_sample.csv, disponível no link https://www.kaggle.com/c/talkingdata-adtracking-fraud-detection/data. Maiores detalhe do desafio também pode ser obtido no site do Kaggle.

Acesse o arquivo Readme para informações complementares.

Carga & visualização

```
oldw <- getOption("warn")
options(warn = -1)

library(dplyr)
```

```
##
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
##
##     filter, lag
```

```
## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```
library(ROSE)
```

```
## Loaded ROSE 0.0-3
```

```
library(lubridate)
```

```
##
## Attaching package: 'lubridate'
```

```
## The following objects are masked from 'package:base':
##
##     date, intersect, setdiff, union
```

```
library(ggplot2)
library(gridExtra)
```

```
##
## Attaching package: 'gridExtra'
```

```
## The following object is masked from 'package:dplyr':
##
##     combine
```

```
#Diretório de trabalho
setwd('D:/OneDrive/EstudosTecnicos/CienciaDados/DtScienceTrab/BigDataRAzure/Cap20/Projeto01')

# Carregar dados - Utilizada a base train-sample.csv devido ao tamanho da base train
dfDados<- read.csv('train_sample.csv', stringsAsFactors= F, header =T)
```

```
str(dfDados)
```

```
## 'data.frame':    100000 obs. of  8 variables:
##  $ ip             : int  87540 105560 101424 94584 68413 93663 17059 121505 192967 143636 ...
##  $ app            : int  12 25 12 13 12 3 1 9 2 3 ...
##  $ device         : int  1 1 1 1 1 1 1 1 2 1 ...
##  $ os             : int  13 17 19 13 1 17 17 25 22 19 ...
##  $ channel        : int  497 259 212 477 178 115 135 442 364 135 ...
##  $ click_time     : chr  "2017-11-07 09:30:38" "2017-11-07 13:40:27" "2017-11-07 18:05:24" "2017-11-0
##  $ attributed_time: chr  "" "" "" "" ...
##  $ is_attributed  : int  0 0 0 0 0 0 0 0 0 0 ...
```

```
# View(dfDados)
summary(dfDados)
```

```
##        ip              app              device              os
##  Min.   :     9   Min.   :  1.00   Min.   :   0.00   Min.   :  0.00
##  1st Qu.: 40552   1st Qu.:  3.00   1st Qu.:   1.00   1st Qu.: 13.00
##  Median : 79827   Median : 12.00   Median :   1.00   Median : 18.00
##  Mean   : 91256   Mean   : 12.05   Mean   :  21.77   Mean   : 22.82
##  3rd Qu.:118252   3rd Qu.: 15.00   3rd Qu.:   1.00   3rd Qu.: 19.00
##  Max.   :364757   Max.   :551.00   Max.   :3867.00   Max.   :866.00
##     channel       click_time        attributed_time    is_attributed
##  Min.   :  3.0   Length:100000      Length:100000      Min.   :0.00000
##  1st Qu.:145.0   Class :character   Class :character   1st Qu.:0.00000
##  Median :258.0   Mode  :character   Mode  :character   Median :0.00000
##  Mean   :268.8                                         Mean   :0.00227
##  3rd Qu.:379.0                                         3rd Qu.:0.00000
##  Max.   :498.0                                         Max.   :1.00000
```

Explorar

Download (e o não download) do App por número de clicks repetidos para diversas variáveis

A quantidade de cliks que não resultam em download para o mesmo IP chama a atenção, sugere fraude. Em outras variáveis essa característica é semelhante, porém não sugestiona fraude na mesma proporção do IP.

```
    # ip
    #par(mfrow = c(1,2))
    dfAux<- dfDados %>%
        select(is_attributed, ip) %>%
        group_by(is_attributed, ip) %>%
        summarise(repeticoes=n())
```

```
## `summarise()` regrouping output by 'is_attributed' (override with `.groups` argument)
```

```
    plot01<- dfAux %>% filter(is_attributed == 1) %>% arrange(desc(repeticoes)) %>% head(6)  %>%
        ggplot(aes(factor(ip), repeticoes)) +
        geom_col() +
        ggtitle('Qtde clicks-IP-APPs baixados-TOP 6') +
        xlab('IPs') +
        ylab('Qtde de clicks por IP')

    plot02<- dfAux %>% filter(is_attributed == 0) %>% arrange(desc(repeticoes)) %>% head(6) %>%
        ggplot(aes(factor(ip), repeticoes)) +
        geom_col() +
        ggtitle('Qtde clicks-IP-APPs NÃO baixados-TOP 6') +
        xlab('IPs') +
        ylab('Qtde de clicks por IP')

    # app
    dfAux<- dfDados %>%
        select(is_attributed, app) %>%
        group_by(is_attributed, app) %>%
        summarise(repeticoes=n())
```

```
## `summarise()` regrouping output by 'is_attributed' (override with `.groups` argument)
```

```
    plot03<- dfAux %>% filter(is_attributed == 1) %>% arrange(desc(repeticoes)) %>% head(6)  %>%
        ggplot(aes(factor(app), repeticoes)) +
        geom_col() +
        ggtitle('Qtde clicks-Aplicativo-APPs baixados-TOP 6') +
        xlab('Aplicativos') +
        ylab('Qtde de clicks por Aplicativos')

    plot04<- dfAux %>% filter(is_attributed == 0) %>% arrange(desc(repeticoes)) %>% head(6) %>%
        ggplot(aes(factor(app), repeticoes)) +
        geom_col() +
        ggtitle('Qtde clicks-Aplicativo-APPs NÃO baixados-TOP 6') +
        xlab('Aplicativos') +
        ylab('Qtde de clicks por Aplicativos')


    # device
    dfAux<- dfDados %>%
        select(is_attributed, device) %>%
        group_by(is_attributed, device) %>%
        summarise(repeticoes=n())
```

```
## `summarise()` regrouping output by 'is_attributed' (override with `.groups` argument)
```

```
    plot05<- dfAux %>% filter(is_attributed == 1) %>% arrange(desc(repeticoes)) %>% head(6)  %>%
        ggplot(aes(factor(device), repeticoes)) +
        geom_col() +
        ggtitle('Qtde clicks-Device-APPs baixados-TOP 6') +
        xlab('Device') +
        ylab('Qtde de clicks por Device')

    plot06<- dfAux %>% filter(is_attributed == 0) %>% arrange(desc(repeticoes)) %>% head(6) %>%
        ggplot(aes(factor(device), repeticoes)) +
        geom_col() +
```

```
          ggtitle('Qtde de clicks-Device-APPs NÃO baixados-TOP 6') +
          xlab('Device') +
          ylab('Qtde de clicks por Device')

     # OS (Sistema Operacional)
     dfAux<- dfDados %>%
          select(is_attributed, os) %>%
          group_by(is_attributed, os) %>%
          summarise(repeticoes=n())
```

```
## `summarise()` regrouping output by 'is_attributed' (override with `.groups` argument)
```

```
     plot07<- dfAux %>% filter(is_attributed == 1) %>% arrange(desc(repeticoes)) %>% head(6)  %>%
          ggplot(aes(factor(os), repeticoes)) +
          geom_col() +
          ggtitle('Qtde clicks-OS-APPs baixados-TOP 6') +
          xlab('Device') +
          ylab('Qtde de clicks por OS')

     plot08<- dfAux %>% filter(is_attributed == 0) %>% arrange(desc(repeticoes)) %>% head(6) %>%
          ggplot(aes(factor(os), repeticoes)) +
          geom_col() +
          ggtitle('Qtde clicks-OS-APPs NÃO baixados-TOP 6') +
          xlab('OS') +
          ylab('Qtde de clicks por OS')

     # channel
     dfAux<- dfDados %>%
          select(is_attributed, channel) %>%
          group_by(is_attributed, channel) %>%
          summarise(repeticoes=n())
```

```
## `summarise()` regrouping output by 'is_attributed' (override with `.groups` argument)
```

```
     plot09<- dfAux %>% filter(is_attributed == 1) %>% arrange(desc(repeticoes)) %>% head(6)  %>%
          ggplot(aes(factor(channel), repeticoes)) +
          geom_col() +
          ggtitle('Qtde clicks-Channel-APPs baixados-TOP 6') +
          xlab('Channel') +
          ylab('Qtde de clicks por Channel')

     plot10<- dfAux %>% filter(is_attributed == 0) %>% arrange(desc(repeticoes)) %>% head(6) %>%
          ggplot(aes(factor(channel), repeticoes)) +
          geom_col() +
          ggtitle('Qtde clicks-Channel-APPs NÃO baixados-TOP 6') +
          xlab('Channel') +
          ylab('Qtde de clicks por Channel')
```

```
          #Exibir plots
     grid.arrange(plot01, plot02, plot03, plot04, ncol=2, nrow=2)
```

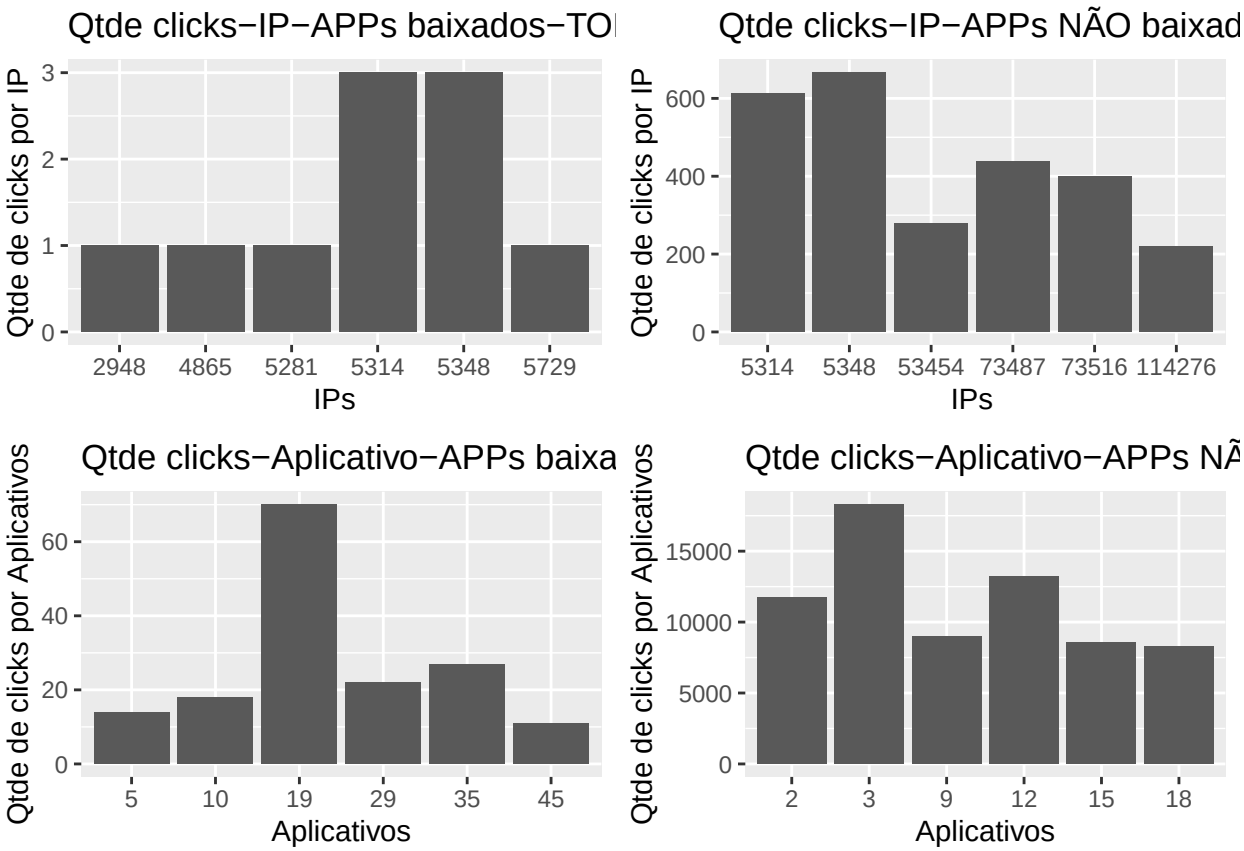


```
grid.arrange(plot05, plot06, plot07, plot08, ncol=2, nrow=2)
```

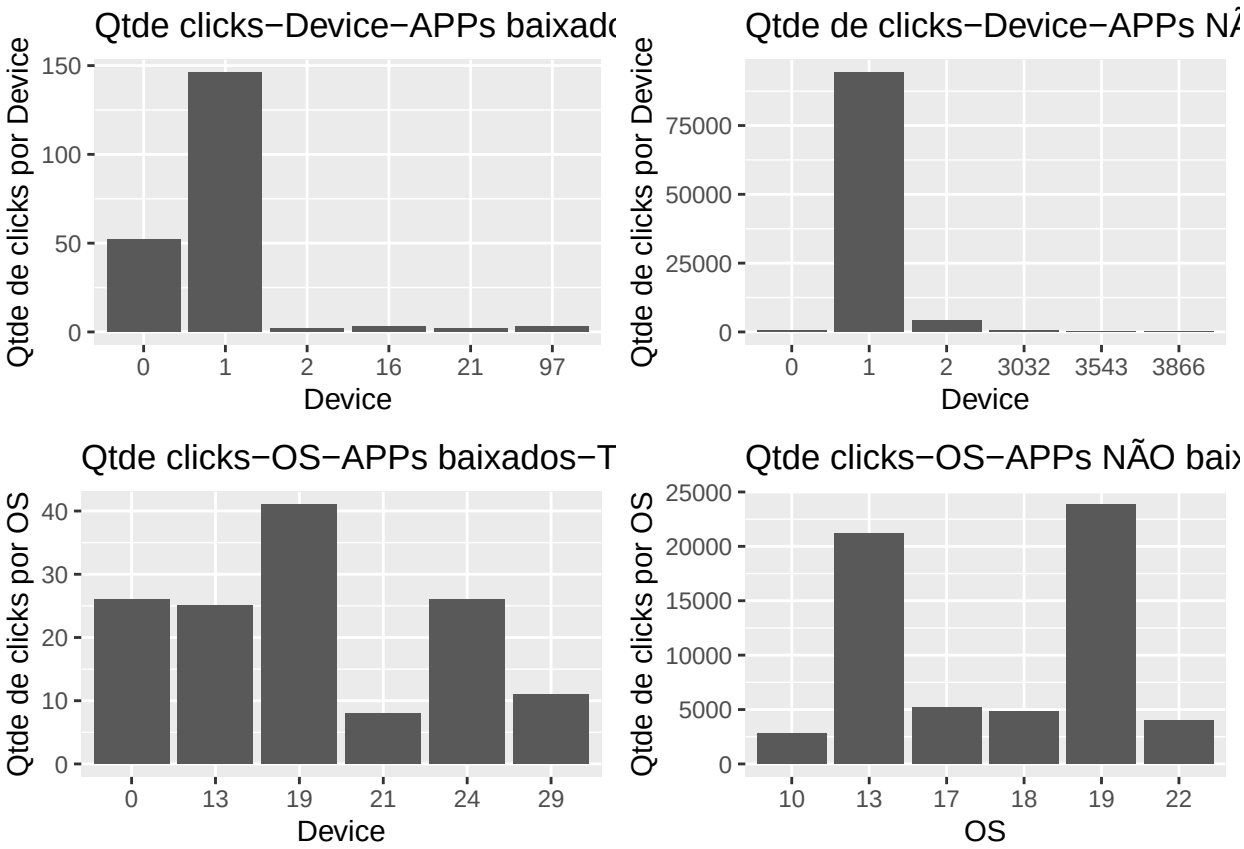


```
grid.arrange(plot09, plot10, ncol=2, nrow=1)
```

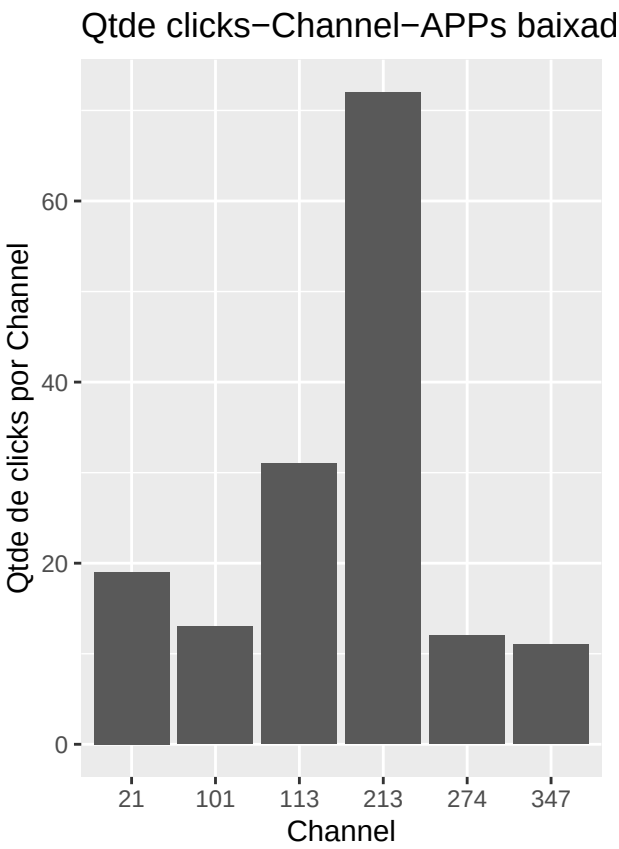

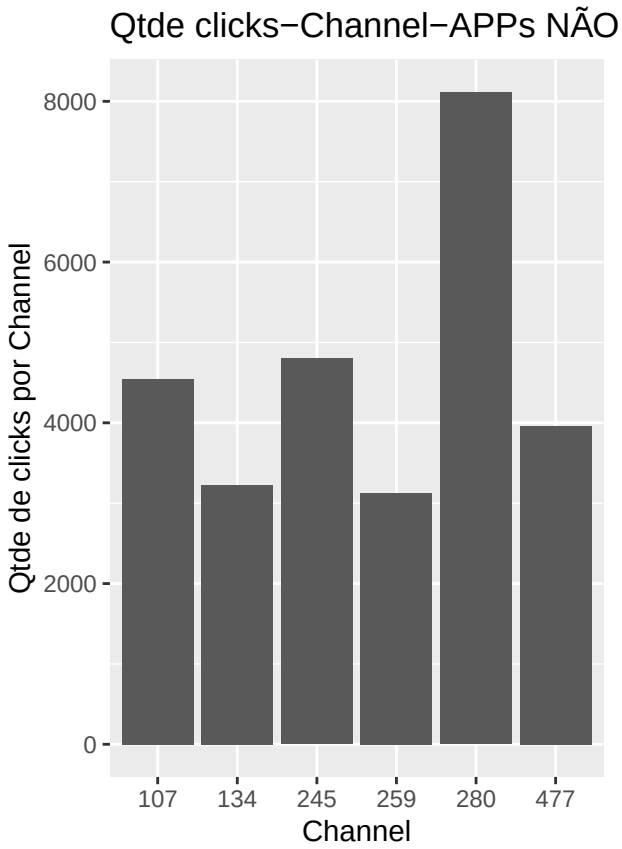

Relação attributed_time X is_attributed

Se App baixado implica na existendia do atributed_time, assim essa variável é consequência da variável target (is_attributed), não pode figurar como perditora

```
    nrow(dfDados %>% filter(attributed_time == ''))
```

```
## [1] 99773
```

```
    nrow(dfDados %>% filter(is_attributed == '0'))
```

```
## [1] 99773
```

```
    nrow(dfDados %>% filter(attributed_time == '' & is_attributed == '0'))
```

```
## [1] 99773
```

```
    dfDados$attributed_time <- NULL
```

Análise temporal

Variável click_time - indica o momento do click.

```
    dfDados$dt <- date(dfDados$click_time)
    dfDados$year <- year(dfDados$dt)
    dfDados$month <- month(dfDados$dt)
    dfDados$day <- day(dfDados$dt)
    dfDados$weekday <- wday(dfDados$dt)
```

```
    dfDados$hour <- hour(dfDados$click_time)
    str(dfDados)
```

```
## 'data.frame':    100000 obs. of  13 variables:
##  $ ip           : int  87540 105560 101424 94584 68413 93663 17059 121505 192967 143636 ...
##  $ app          : int  12 25 12 13 12 3 1 9 2 3 ...
##  $ device       : int  1 1 1 1 1 1 1 1 2 1 ...
##  $ os           : int  13 17 19 13 1 17 17 25 22 19 ...
##  $ channel      : int  497 259 212 477 178 115 135 442 364 135 ...
##  $ click_time   : chr  "2017-11-07 09:30:38" "2017-11-07 13:40:27" "2017-11-07 18:05:24" "2017-11-07
##  $ is_attributed: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ dt           : Date, format: "2017-11-07" "2017-11-07" ...
##  $ year         : num  2017 2017 2017 2017 2017 ...
##  $ month        : num  11 11 11 11 11 11 11 11 11 11 ...
##  $ day          : int  7 7 7 7 9 9 9 7 8 8 ...
##  $ weekday      : num  3 3 3 3 5 5 5 3 4 4 ...
##  $ hour         : int  9 13 18 4 9 1 1 10 9 12 ...
```

```
    # year e month - essas variáveis tem uma dimensão apenas, é
    # como uma constante. A amostra se resuma a um ano e um mês, apenas
    str(factor(dfDados$year))
```

```
##  Factor w/ 1 level "2017": 1 1 1 1 1 1 1 1 1 1 ...
```

```
    str(factor(dfDados$month))
```

```
##  Factor w/ 1 level "11": 1 1 1 1 1 1 1 1 1 1 ...
```

```
    dfDados$year <- NULL
    dfDados$month <- NULL

    # day e weekday - se tornaram redudantes devido ao tamanho da amostra: apenas
    # 4 dias consecutivos no mês 11 de 2017, sendo que não contempla fim de semana
    # nem sinaliza feriados. Qualquer análise de comportamento na linha semanal ou
    # de períodos mensais seria "forçação" de barra.
    # Foi mantida a variável day e eliminada a weekday
    str(factor(dfDados$day))
```

```
##  Factor w/ 4 levels "6","7","8","9": 2 2 2 2 4 4 4 2 3 3 ...
```

```
    dfDados %>% distinct(day) %>% arrange(day)
```

```
##   day
## 1   6
## 2   7
## 3   8
## 4   9
```

```
    str(factor(dfDados$weekday))
```

```
##  Factor w/ 4 levels "2","3","4","5": 2 2 2 2 4 4 4 2 3 3 ...
```

```
    dfDados %>% distinct(weekday) %>% arrange(weekday)
```

```
##   weekday
## 1       2
## 2       3
## 3       4
```

```
## 4       5
```

```
dfDados$weekday <- NULL


# hour - Avaliar comportamento por hora
# O desbalanceamento da classe is_attributed é muito acentuado, isso limita os insighs
# Recomenda-se repetir a análise após o balanceamento da classe. Poderá ser feito em uma
# continuidade desse trabalho.
# Para um análise temporal, a amostra se apresentou bastante limitada.
dfAux<- dfDados %>%
    select(is_attributed, day, hour) %>%
    group_by(is_attributed, day, hour) %>%
    summarise(qtdCliks=n())
```

```
## `summarise()` regrouping output by 'is_attributed', 'day' (override with `.groups` argument)
```

```
# Função - plotagem por dia
plotD <- function(dia){
    plotd1<- ggplot(dfAux[dfAux$is_attributed == 1 & dfAux$day == dia,], aes(x = hour, y = qtdCli
        geom_line() +
        ylab("Qtde de clicks") + xlab("Hora") +
        labs(title = paste("Dia ", as.character(dia), " APP BAIXADOS - Qtde de clicks por hora",

    plotd2<- ggplot(dfAux[dfAux$is_attributed == 0 & dfAux$day == dia,], aes(x = hour, y = qtdCli
        geom_line() +
        ylab("Qtde de clicks") + xlab("Hora") +
        labs(title = paste("Dia ", as.character(dia), " APP NÃO BAIXADOS-Qtde de clicks por hora

    grid.arrange(plotd1 , plotd2, ncol=2, nrow=1)
}

dias<- unlist(distinct(dfAux[, 'day']))
lapply(dias, plotD)
```

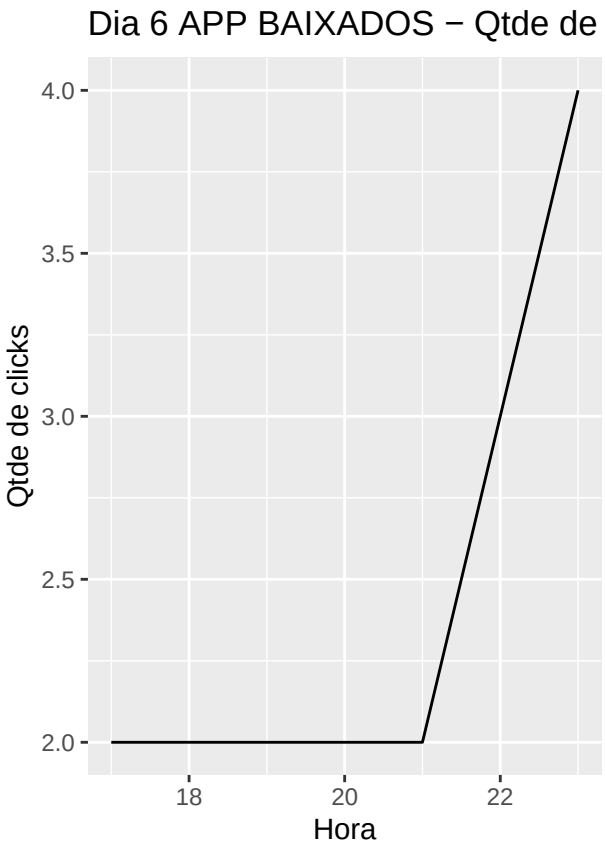
Dia 6 APP BAIXADOS − Qtde de c
Qtde de clicks
4.0
3.5
3.0
2.5
2.0
18
20
22
Hora

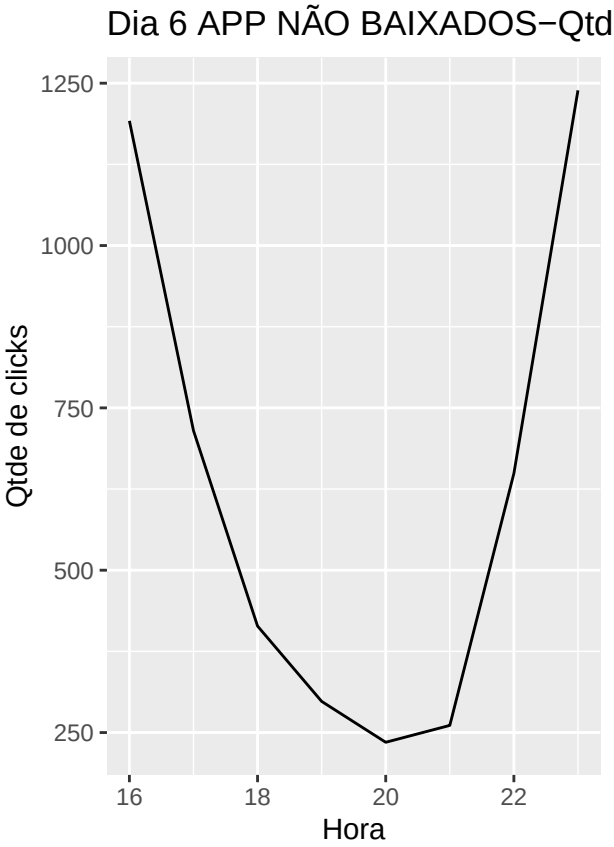
Dia 6 APP NÃO BAIXADOS−Qtd
Qtde de clicks
1250
1000
750
500
250
16
18
20
22
Hora

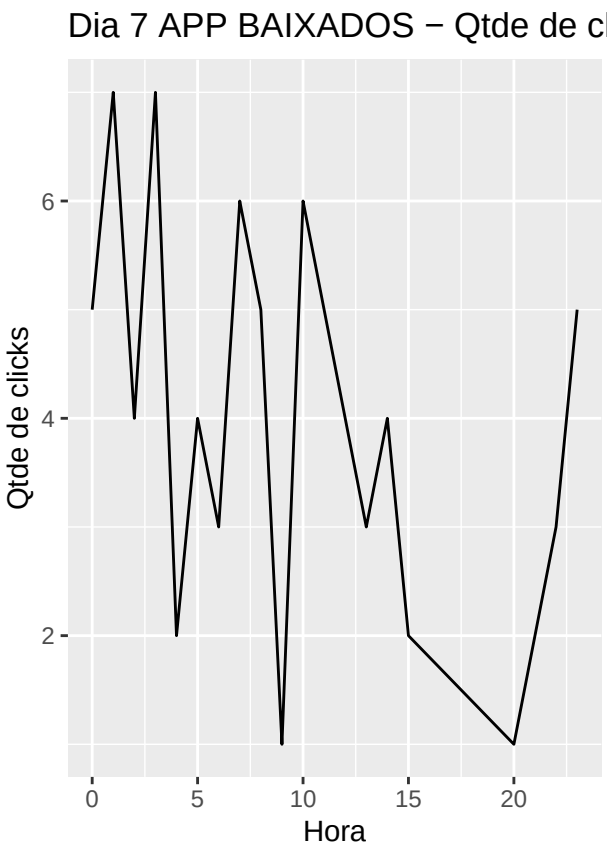
Dia 7 APP BAIXADOS − Qtde de cli
Qtde de clicks
6
4
2
0
5
10
15
20
Hora

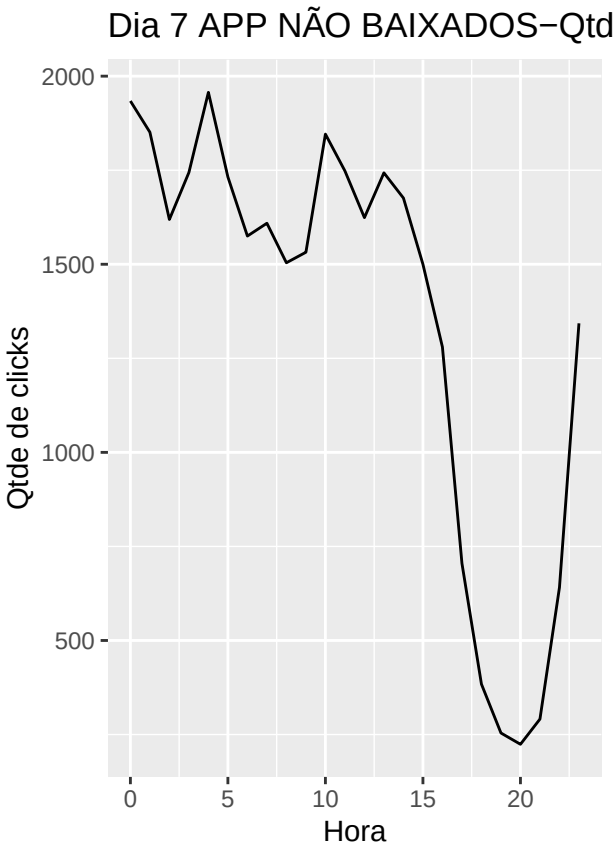
Dia 7 APP NÃO BAIXADOS−Qtd
Qtde de clicks
2000
1500
1000
500
0
5
10
15
20
Hora

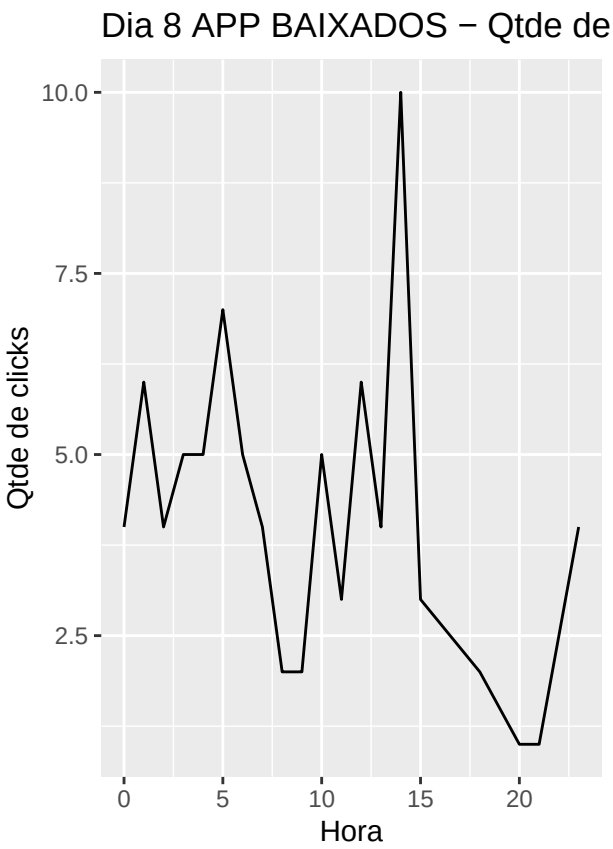
Dia 8 APP BAIXADOS − Qtde de
Qtde de clicks
10.0
7.5
5.0
2.5
0
5
10
15
20
Hora

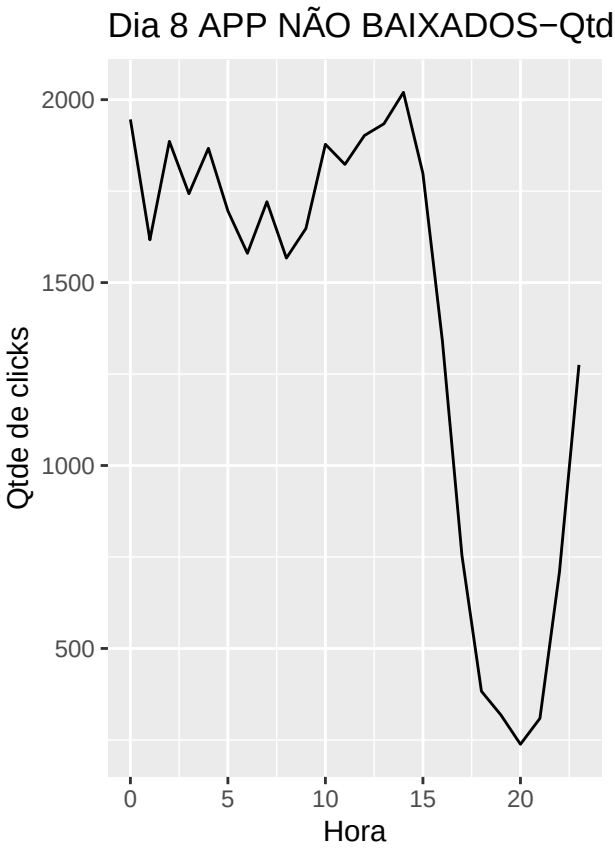
Dia 8 APP NÃO BAIXADOS−Qtd
Qtde de clicks
2000
1500
1000
500
0
5
10
15
20
Hora

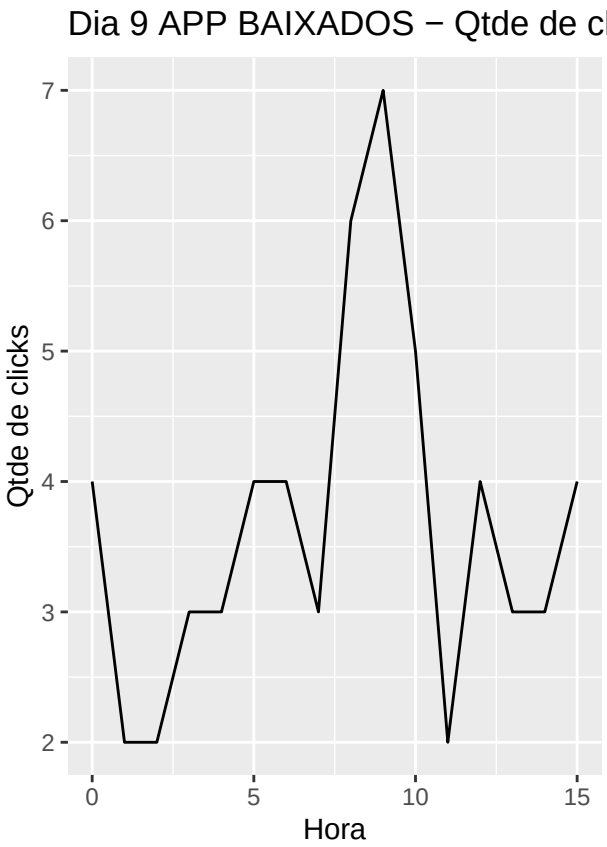

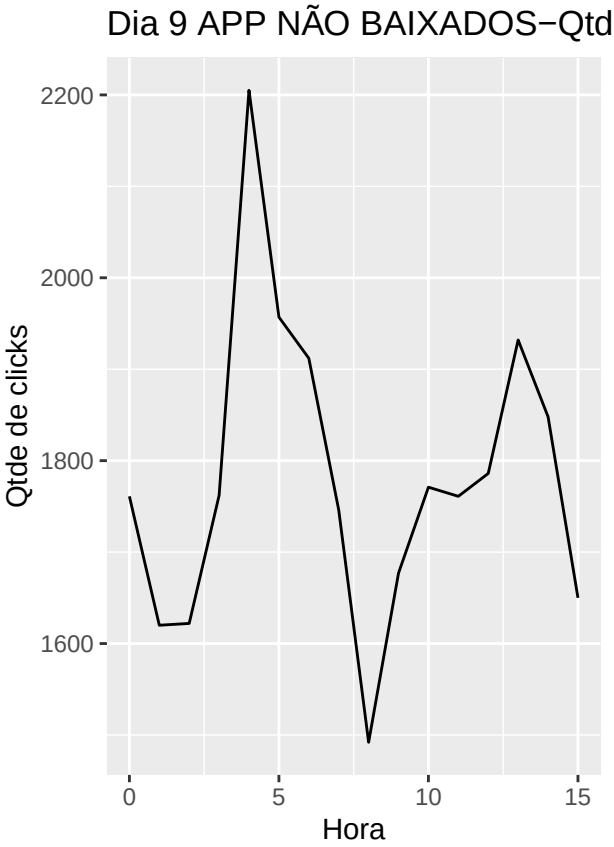


```
## $day1
## TableGrob (1 x 2) "arrange": 2 grobs
##   z     cells    name           grob
## 1 1 (1-1,1-1) arrange gtable[layout]
## 2 2 (1-1,2-2) arrange gtable[layout]
##
## $day2
## TableGrob (1 x 2) "arrange": 2 grobs
##   z     cells    name           grob
## 1 1 (1-1,1-1) arrange gtable[layout]
## 2 2 (1-1,2-2) arrange gtable[layout]
##
## $day3
## TableGrob (1 x 2) "arrange": 2 grobs
##   z     cells    name           grob
## 1 1 (1-1,1-1) arrange gtable[layout]
## 2 2 (1-1,2-2) arrange gtable[layout]
##
## $day4
## TableGrob (1 x 2) "arrange": 2 grobs
##   z     cells    name           grob
## 1 1 (1-1,1-1) arrange gtable[layout]
## 2 2 (1-1,2-2) arrange gtable[layout]
```

Análise de correlação

```
    library(corrgram)
```

```
## Registered S3 method overwritten by 'seriation':
##   method         from
##   reorder.hclust gclus
```

```
    corrgram(dfDados)
```

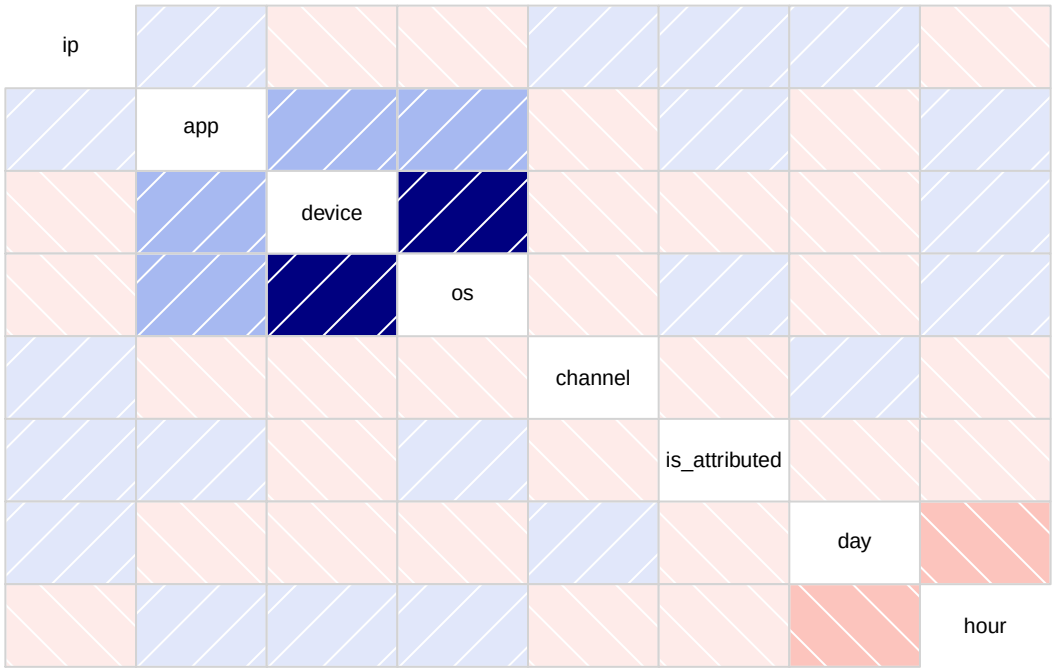

Variáveis categóricas

Reconhecer as variáveis categóricas do dataset. Foram disponisibilizadas com o tipo inteiro

```
    toFactor<- function(df, var) {
        for(v in var) df[,v]= factor(df[,v])
        return(df)
    }

    VarToFactor<- c('ip', 'app','device','os','channel','is_attributed', 'day', 'hour')
    dfDados<- toFactor(dfDados, VarToFactor)
```

Valores missing

Checar e tratar valores missing

```
# Tratar valores NA - Não tem valores missing
    any(is.na(dfDados))
```

```
## [1] FALSE
```

Dados de teste e treino

```
#Divisão dos dados de teste e treino
     linhas <- sample(1:nrow(dfDados), 0.7 * nrow(dfDados))
     dfTrain <- dfDados[linhas,]
     dfTest <- dfDados[-linhas,]
```

Balanceamento de classe

O dataset está bastante desbalenceado em relação a classe is_attributed, variável target.

```
#Balanceamento - Oversampling - is_attributed - muito mais registros com valor 0
     summary(dfTrain$is_attributed)
```

```
##     0     1
## 69845   155
```

```
     prop.table(table(dfTrain$is_attributed))
```

```
##
##           0           1
## 0.997785714 0.002214286
```

```
     barplot(prop.table(table(dfTrain$is_attributed)))
```

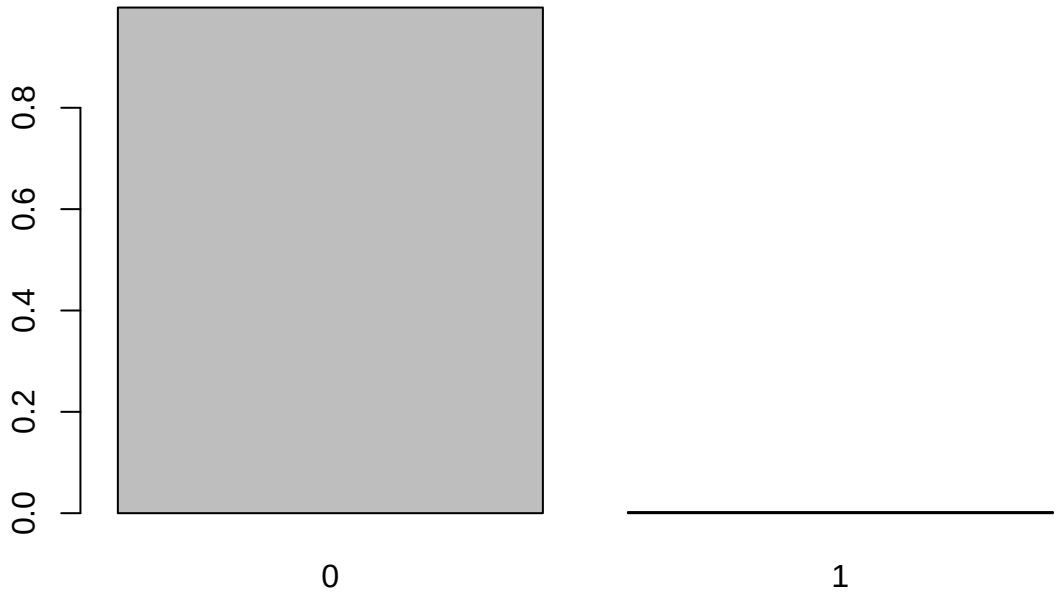

```
    dfTrainBal <- ROSE(is_attributed ~ ip +
                         app +
                         device +
                         os +
                         channel +
                         day +
                         hour,
                       data = dfTrain, seed = 1)$data

    # Nova Proporção
    summary(dfTrainBal$is_attributed)
```

```
##     0     1
## 34919 35081
```

```
    prop.table(table(dfTrainBal$is_attributed))
```

```
##
##         0         1
## 0.4988429 0.5011571
```

```
    barplot(prop.table(table(dfTrainBal$is_attributed)))
```

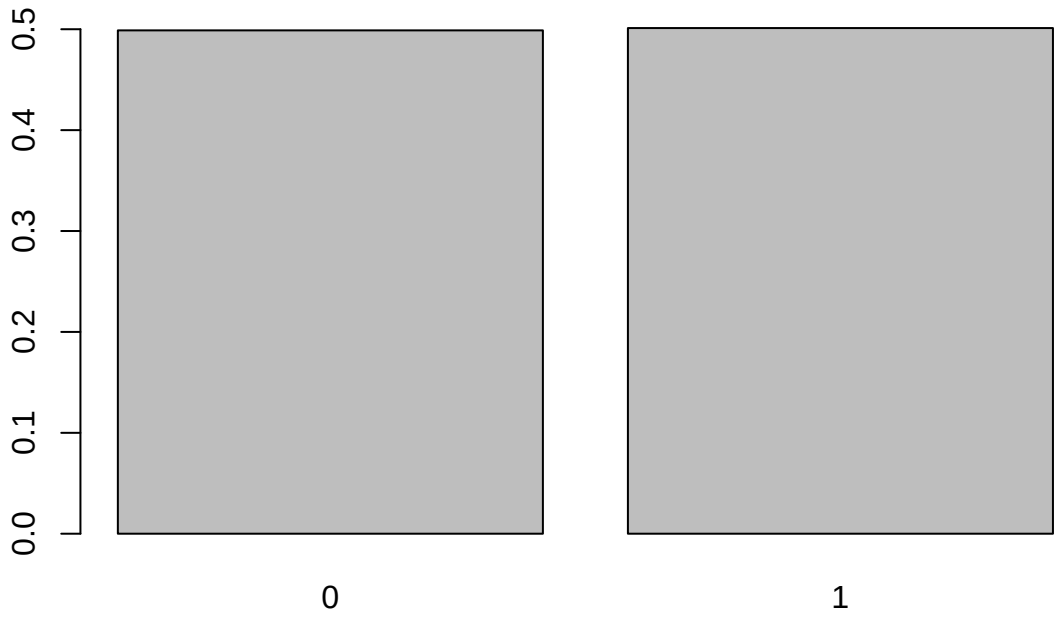


```
    any(is.na(dfTrainBal))
```

```
## [1] FALSE
```

```
# Balancear Teste
    dfTestBal <- ROSE(is_attributed ~ ip +
                                app +
                                device +
                                os +
                                channel +
                                day +
                                hour,
                            data = dfTest, seed = 1)$data
    summary(dfTestBal$is_attributed)
```

```
##     0     1
## 15121 14879
```

```
    prop.table(table(dfTestBal$is_attributed))
```

```
##
##         0         1
## 0.5040333 0.4959667
```

```
    barplot(prop.table(table(dfTestBal$is_attributed)))
```

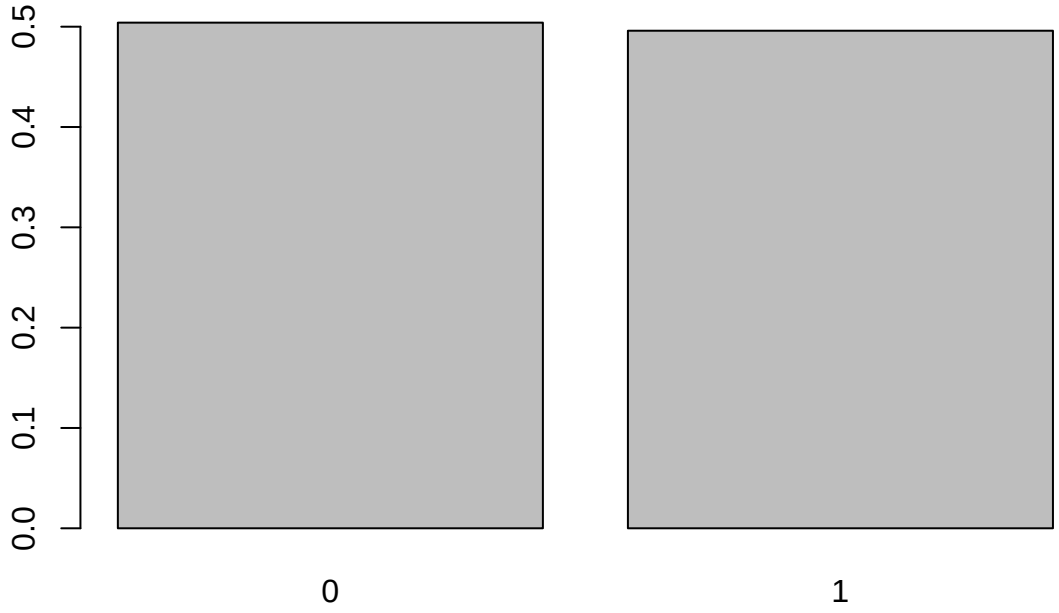


```
    any(is.na(dfTestBal))
```

```
## [1] FALSE
```

Treinando modelos

OBS: O Radom Forest não aceita trabalhar com variáveis categóricas com mais de 53 níveis. Por esse motivo, algumas Variáveis foram ajustadas para o tipo character.

```
    library(C50) #algorítimo C5.0
    library(e1071) #naiveBayes
    library(randomForest)
```

```
## randomForest 4.6-14
```

```
## Type rfNews() to see new features/changes/bug fixes.
```

```
##
## Attaching package: 'randomForest'
```

```
## The following object is masked from 'package:gridExtra':
##
##     combine
```

```
## The following object is masked from 'package:ggplot2':
##
##     margin
```

```
## The following object is masked from 'package:dplyr':
##
##     combine
```

```
    #Árvore de decisão - algorítimo C5.0
    m.Arvore1 <- C5.0(is_attributed ~ ., data = dfTrainBal, rules = TRUE)

    # naiveBayes
    m.Naive1<- naiveBayes(is_attributed ~ ., data = dfTrainBal, laplace = 0)

    # Radom Forest - Não aceita trabalhar com factor com mais de 53 níveis. Variáveis
    # ajustadas para o tipo character.
    dfTrainBalRandom<- dfTrainBal
    dfTrainBalRandom$ip<- as.character(dfTrainBalRandom$ip)
    dfTrainBalRandom$app<- as.character(dfTrainBalRandom$app)
    dfTrainBalRandom$device<- as.character(dfTrainBalRandom$device)
    dfTrainBalRandom$os<- as.character(dfTrainBalRandom$os)
    dfTrainBalRandom$channel<- as.character(dfTrainBalRandom$channel)
    #str(dfTrainBalRandom)

    m.Random1 <- randomForest( is_attributed ~ ip +
                                   app +
                                   device +
                                   os +
                                   channel +
                                   day +
                                   hour,
                               data = dfTrainBalRandom,
                               ntree = 100, nodesize = 10)
```

Predição e avaliação

```r
# Predições
    p.Arvore1<- predict(m.Arvore1, dfTestBal)
    p.Naive1<- predict(m.Naive1, dfTestBal)

    dfTestBalRandom<- dfTestBal
    dfTestBalRandom$ip<- as.character(dfTestBalRandom$ip)
    dfTestBalRandom$app<- as.character(dfTestBalRandom$app)
    dfTestBalRandom$device<- as.character(dfTestBalRandom$device)
    dfTestBalRandom$os<- as.character(dfTestBalRandom$os)
    dfTestBalRandom$channel<- as.character(dfTestBalRandom$channel)
    p.Random1<- predict(m.Random1, dfTestBalRandom)
```

```r
#Avaliando predições
    library(caret)
```

```
## Loading required package: lattice
```

```
##
## Attaching package: 'lattice'
```

```
## The following object is masked from 'package:corrgram':
##
##     panel.fill
```

```r
    confusionMatrix(dfTestBal$is_attributed, p.Arvore1)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction     0     1
##          0 13136  1985
##          1  3940 10939
##
##                Accuracy : 0.8025
##                  95% CI : (0.7979, 0.807)
##     No Information Rate : 0.5692
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.6046
##
##  Mcnemar's Test P-Value : < 2.2e-16
##
##             Sensitivity : 0.7693
##             Specificity : 0.8464
##          Pos Pred Value : 0.8687
##          Neg Pred Value : 0.7352
##              Prevalence : 0.5692
##          Detection Rate : 0.4379
##    Detection Prevalence : 0.5040
##       Balanced Accuracy : 0.8078
##
##        'Positive' Class : 0
##
```

```r
    confusionMatrix(dfTestBal$is_attributed, p.Naive1)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction     0     1
##          0 14067  1054
##          1  1889 12990
##
##                Accuracy : 0.9019
##                  95% CI : (0.8985, 0.9052)
##     No Information Rate : 0.5319
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.8037
##
##  Mcnemar's Test P-Value : < 2.2e-16
##
##             Sensitivity : 0.8816
##             Specificity : 0.9250
##          Pos Pred Value : 0.9303
##          Neg Pred Value : 0.8730
##              Prevalence : 0.5319
##          Detection Rate : 0.4689
##    Detection Prevalence : 0.5040
##       Balanced Accuracy : 0.9033
##
##        'Positive' Class : 0
##
```

```
confusionMatrix(dfTestBal$is_attributed, p.Random1)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction     0     1
##          0 15094    27
##          1 14387   492
##
##                Accuracy : 0.5195
##                  95% CI : (0.5139, 0.5252)
##     No Information Rate : 0.9827
##     P-Value [Acc > NIR] : 1
##
##                   Kappa : 0.0315
##
##  Mcnemar's Test P-Value : <2e-16
##
##             Sensitivity : 0.51199
##             Specificity : 0.94798
##          Pos Pred Value : 0.99821
##          Neg Pred Value : 0.03307
##              Prevalence : 0.98270
##          Detection Rate : 0.50313
##    Detection Prevalence : 0.50403
##       Balanced Accuracy : 0.72998
##
```

```
##        'Positive' Class : 0
##
```

```
# ROC Curves com o ROSE
    roc.curve(dfTestBal$is_attributed, p.Arvore1, plotit = T, col = "orange", add.roc = F)
```

```
## Area under the curve (AUC): 0.802
```

```
    roc.curve(dfTestBal$is_attributed, p.Naive1, plotit = T, col = "red", add.roc = T)
```

```
## Area under the curve (AUC): 0.902
```

```
    roc.curve(dfTestBal$is_attributed, p.Random1, plotit = T, col = "blue", add.roc = T)
```

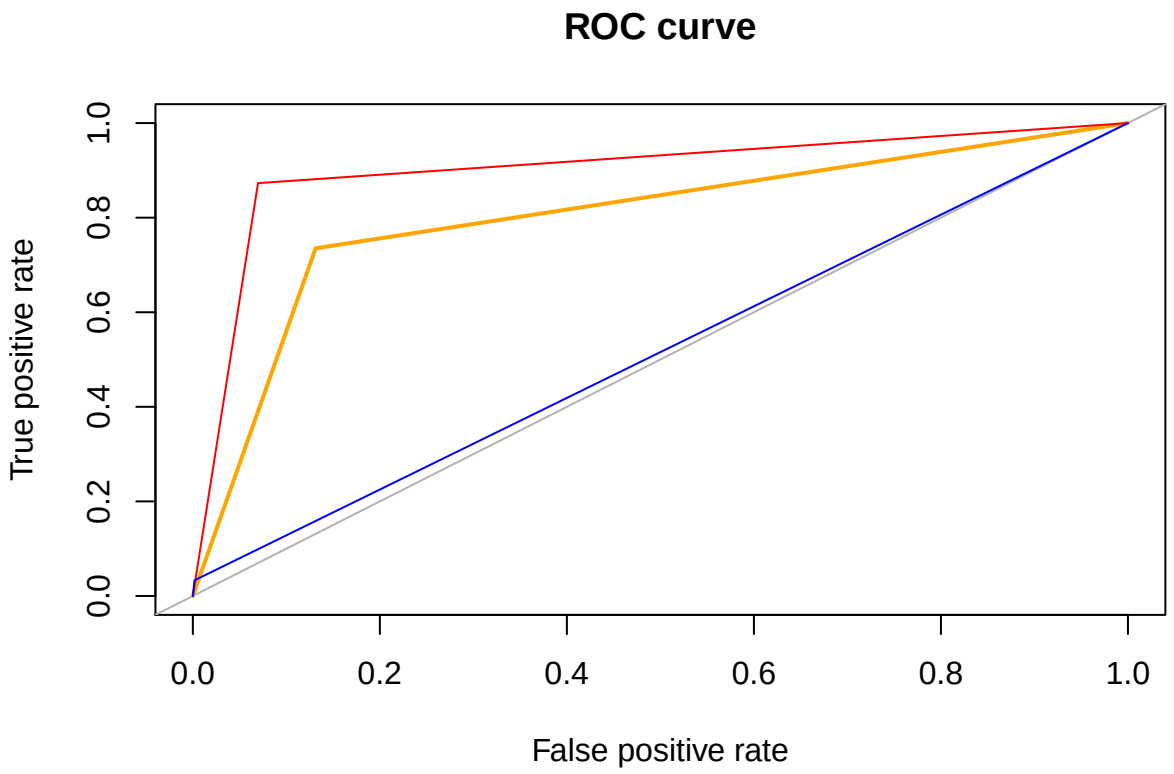


```
## Area under the curve (AUC): 0.516
```

```
options(warn = oldw)
```

Conclusões

O moldelo baseado no Naive apresentou melhor acurácia, poderia seguir com um refinamento do processo de otimização.

O C5.0 vem em seguida. Apresenta também como candidado a seguir com uma otimização.

O modelo de Radom Forest não conseguiu rodar com as variáveis categóricas (factor) com mais de 53 níveis. Assim, algumas variáveis foram convertidas para caracter. isso pode ter influenciando no seu baixo desempenho.

OBS: aqui não se fez um trabalho expoloratório com os dados balanceados por se tratar de um projeto

acadêmico, cuja finalidade maior é foi o exercício inicial da análise sobre dados. Essa exploração não seria nos dados de treino ou teste, seria em dataframe específico para esse fim.